




2025/07/04

Development of a Model for Prediction of Subsidence in Seoul Area Using Machine Learning

Presented by: Yoonsung Chung



ABM->MACHINE LEARNING 일반적인 학습 과정

데이터 정리 및 추가(~2025/05/16)



전처리/피쳐 가공(~2025/05/20)



라벨 정의(TP,FN,TN,FP)(~2025/05/24)



데이터 수집 및 분할(~2025/05/31)



모델 학습(~2025/06/27)



성능 평가(~2025/06/27)



튜닝 및 재학습(현재 진행중)





EGU 학회에서의 경험 (데이터셋은 어디서?)

참여 세션


(MACHINE LEARNING AND DIGITAL TWINS FOR EARTH SYSTEM OBSERVATION AND PREDICTION)



충분하고 출처가 정확한 데이터를 활용한 학습 필요




지반침하(싱크홀, 지반함몰)와 같은 사건은 발생 빈도가 낮아 학습 데이터 부족(강동구 5건)




유사한 상황에서 어떤식으로 데이터를 활용했는지 논문 확인 및 서울시 전체로 확장

WHAT IS GRAPH NEURAL NETWORK?



데이터가 '그래프 구조'로 표현 가능(CSV테이블 형식 → 그래프형식)

- 노드(NODE): 관로 단위, 나무 위치, 시추공, 민원 발생 지점 등
- 엣지(EDGE): 공간적 거리, 연결 관계, 공통 속성(예: 같은 관로망) 등




노드 간 상호작용 학습에 강함

- GNN은 단순히 노드의 고립된 정보가 아니라 이웃 노드와의 관계를 통해 학습함
- 어떤 노후 관로가 고립되어 있으면 위험도가 낮음
- 노후 관로 + 오래된 나무 + 얇은 지층이 연결돼 있다면 위험도는 상승


GRAPH NEURAL NETWORK

Graph Example for GNN in Ground Sink Prediction




GNN은 네트워크 전체 구조를 통해 간접 학습을 수행할 수 있어 학습 데이터가 적어도 의미 있는 예측이 가능

WHY GRAPH NEURAL NETWORK?



기존 모델의 한계

- 일반적인 머신러닝 모델은 각 데이터를 독립된 개체로 간주합니다. (예: A 관로는 A 관로일 뿐, 옆의 B 관로와는 무관)
- 하지만 지반침하와 같은 문제는, 특정 관로 하나의 상태보다 주변 관로들과의 상호작용이 더 중요



GNN의 접근 방식

- GNN(GRAPH NEURAL NETWORK)은 점(NODE)과 선(EDGE)으로 구성된 그래프(GRAPH) 데이터를 처리하기 위해 탄생한 딥러닝 모델
- GNN은 각 관로를 독립된 데이터가 아닌, 서로 연결된 네트워크의 일부로 보고, 노드 간의 관계와 그래프의 전체적인 구조를 학습



GNN(GRAPH NEURAL NETWORK)에 활용할 노드 데이터 정리

시추공(토질) 노드 → USCS 코드(>0.75)

하수관망 노드 → 하수관 연식, 하수관 지름

가로수 노드 → 5M 반경제한

지하철 노드 → 20M 반경 제한

추가위험노드 → 20M~50M 반경 제한

데이터들의 출처?

최대한 공공기관 데이터 활용(누구나 접근가능)

**시추공(토질)데이터, 실제 지반침하 신고 데이터, 지하수위 데이터 → 국토교통부 지하안전정보시스템
(미래스마트건설연구본부)**

하수관망 데이터 → 연구실(서울시)

가로수 데이터 -> 서울특별시 푸른도시국 조경과

지하철 위치 및 반경 데이터 -> 서울교통공사

서울지역내의 지하철 및 실제 지반침하 데이터

SEOUL SUBWAY MAP




FIG 5.서울지역내 지하철노선 데이터

SEOUL SUBSIDENCE MAP





FIG 6. 서울지역내 지반침하 위치 데이터

논문상 상관관계 분석결과

요인	주요 상관계수(최대)	P-value 유의성	해석
노후도 (1972-1991)	0.5603 (강한 상관)	유의(<0.005)	노후관로가 주요 원인
지름 (0-1000mm)	0.5818 (강한 상관)	유의(<0.005)	중소형 관로가 위험
길이 (수도관)	0.5875 (강한 상관)	유의(<0.005)	수도관 길이가 영향 큼
지층정보	-0.3~0.3 (낮음)	무의미(>0.005)	지층정보는 영향 없음

->논문의 결과는 **노후된 하수도관**과 **하수관의 길이** 및 **중소형 지름**이 도시 지반침하의 주요 원인임을 강조함
지층정보는 이 연구에서 통계적으로 유의하지 않았으나, 향후 다른 방법론과 더 정밀한 분석이 추가되면 다시 평가될수 있음

->GNN 분석시 노후도, 지름활용



GNN 중 어떠한 모델이 가장 적합한가?

모델 (Model)	핵심 아이디어	정보 종합 방식	주요 특징
GCN	이웃노드들의 평균 가중치	주변 이웃 정보의 정규화된 평균	간단하고 효율적, 강력한 기준 모델
SAGE	무작위 샘플링과 일반화	이웃을 샘플링한 뒤 정보 종합	대규모 그래프에 적용 가능, 귀납적
GAT	중요한 노드에게 더 집중	이웃에 대해 다른 가중치를 학습	높은 성능, 결과 해석에 용이

GNN 중 어떠한 모델이 가장 적합한가?



개요


- 세 가지 GNN 모델(GAT, GCN, SAGE)의 핵심 성능 지표인 F1-SCORE, AUC를 한눈에 비교하여 종합적인 성능 우위를 파악

주요 결과

- AUC (변별력):** GAT 모델의 AUC 점수(0.9410)가 다른 모델들을 압도적으로 상회, 이는 GAT가 위험 지역과 안전 지역을 구분하는 능력이 매우 뛰어나다는 것을 의미함. 반면, SAGE 모델은 0.5 미만으로 유의미한 학습에 실패했음을 보여줌
- F1-SCORE (종합 성능):** GAT 모델의 F1-SCORE(0.0381)가 가장 높음. 이는 낮은 정밀도 문제에도 불구하고, 위험 탐지 능력(재현율)을 종합적으로 고려했을 때 가장 균형 잡힌 모델임을 시사함.

-> 종합적으로 GAT 모델이 가장 우수한 성능을 보였으며, 특히 모델의 신뢰도를 나타내는 AUC 지표에서 드러남

GNN 중 어떠한 모델이 가장 적합한가?



개요

- 단순 점수를 넘어, 각 모델이 어떤 종류의 예측을 하고 어떤 실수를 저지르는지 그 패턴과 성향을 비교 분석하여 모델의 신뢰도를 평가

주요 결과

- TP & FN (탐지 능력): GAT 모델은 실제 위험 3건 중 2건을 탐지(TP=2)하고 단 1건만 놓쳐(FN=1), 가장 뛰어난 위험 탐지 능력을 보여줌. 반면, GCN은 단 한 건도 탐지하지 못했으며(FN=3), SAGE는 2건을 놓침(FN=2).
- FP (오경보): 모든 모델이 다수의 오경보(FP)를 발생시키는 문제를 보이지만, GAT 모델(100건)이 가장 적은 수의 오경보를 기록하며 가장 효율적인 예측. GCN(145건)과 SAGE(326건)는 훨씬 더 많은 오경보를 발생시킴

-> GAT 모델은 '실제 위험을 가장 잘 찾아내면서도, 불필요한 오경보는 가장 적게 발생시키는 가장 신뢰도 높은 모델

GNN 중 어떠한 모델이 가장 적합한가?

Model	Accuracy	AUC	F1-Score	TP (성공)	FN (놓친 위험)	FP (오경보)
GCN	0.932	0.7174	0	0	3	145
SAGE	0.8493	0.4925	0.0061	1	2	326
GAT	0.9536	0.941	0.0381	2	1	100

GAT 내의 수학적 분석

$$e_{ij} = a(\mathbf{W}\vec{h}_i, \mathbf{W}\vec{h}_j)$$

ATTENTION COEFFICIENT



$$\alpha_{ij} = \text{softmax}_j(e_{ij}) = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}_i} \exp(e_{ik})}$$

ATTENTION COEFFICIENT BASED ON MASKED ATTENTION (NORMALIZED)


$$\alpha_{ij} = \frac{\exp \left(\text{LeakyReLU} \left(\vec{a}^T [\mathbf{W}\vec{h}_i \parallel \mathbf{W}\vec{h}_j] \right) \right)}{\sum_{k \in \mathcal{N}_i} \exp \left(\text{LeakyReLU} \left(\vec{a}^T [\mathbf{W}\vec{h}_i \parallel \mathbf{W}\vec{h}_k] \right) \right)}$$

FINAL ATTENTION COEFFICIENT

GAT 내 구조적 분석



모델의 평가 방식




그래프 목적

모델이 학습을 안정적으로 수행했는지, 과적합 문제는 없는지 검증

- **TRAIN LOSS (학습 오차):** 지속적으로 감소하며 모델이 데이터를 잘 학습하고 있음을 시사
- **VALIDATION LOSS (검증 오차):** 학습 오차와 유사한 패턴으로 감소하며, 과적합 없이 새로운 데이터에 대해서도 일반화 성능을 확보했음을 증명
- 두 손실 곡선이 함께 수렴하는 것은 매우 이상적인 학습 패턴임. 이는 현재 모델 구조와 학습 설정(LEARNING RATE, DROPOUT 등)이 데이터에 적합하게 기능하고 있음을 의미

모델의 평가 방식




그래프 목적

모델의 예측 확률을 '위험/안전'으로 분류하는 가장 효과적인 기준점을 도출하고, 그 선택의 타당성을 시각적으로 제시

- X축: 위험 판단의 기준이 되는 확률 임계값 THRESHOLD(0.05 ~ 0.95)
- Y축: 모델의 종합 성능 지표인 F1-SCORE
- 붉은 점선: F1-SCORE가 최대가 되는 최적 임계값(0.95) 지점을 표시
- 일반적으로 알려진 THRESHOLD 값 0.5를 기준으로 삼는 것보다, F1-SCORE를 최대로 만드는 0.95를 최종 기준으로 채택하는 것이 모델의 성능을 가장 잘 활용하는 방법임을 보여줌
- 이는 모델이 매우 높은 확신을 가지고 예측한 경우에만 '위험'으로 판단하는 것이 가장 효과적이라는 것을 의미

모델의 평가 방식




그래프 목적

최종 선택된 모델과 임계값의 성능을 예측 유형별로 상세히 분석

- 핵심 내용 FN (FALSE NEGATIVE) = 0 → 모델이 실제 위험 지역을 단 한 건도 놓치지 않았음 (재현율 100%)
→ 위험 예측 모델로서 가장 중요한 목표 달성.
- TP (TRUE POSITIVE) = 3 → 테스트 데이터 내의 실제 위험 지역 3곳을 모두 정확히 예측함.
- FP (FALSE POSITIVE) = 543 → 543개의 안전한 지역을 위험하다고 잘못 예측함 (낮은 정밀도).
- 오경보(FP)가 많다는 단점은 있지만, 위험 관리 측면에서는 모든 위험을 식별해냈다는 점에서 매우 의미 있는 결과
향후 과제는 FP를 줄여 정밀도를 높이는 것

모델의 평가 방식




그래프 목적

모델의 최종 예측 결과를 실제 지리 정보 위에 시각화하여, 공간적 위험 분포를 직관적으로 제시

- **점 색상:** 각 관로의 예측된 침하 위험 확률 (보라색: 낮음 ↔ 노란색: 높음)
- **붉은 별:** 실제 침하가 발생했던 위치 (GROUND TRUTH)
- **모델이 예측한 고위험 지역(노란색 점)들이 실제 침하 지점(붉은 별) 주변에 군집을 이루는 경향을 확인할 수 있습니다.**
- **이는 GNN 모델이 단순히 개별 관로의 특성뿐만 아니라, 주변 지역의 공간적 맥락을 성공적으로 학습했음을 시각적으로 증명**


어떤 도로망이나 블록을 따라 위험도가 높게 나타나는지 분석하여, 향후 현장 조사의 우선순위를 정하는 데 활용

GNN Prediction vs. Real Subsidence Locations




요소별 침하 영향 그래프

Feature Importance (Permutation Method)




서울시 전체로의 확장

Model Training & Validation Loss Curve



데이터 양이 방대해짐 -> 오차 감소

Feature Importance (Permutation Method)




지하철노선과의 거리 중요도


서울시 전체로의 확장

격자별 위험도 점수 = (격자 내 관로들의 평균 위험 확률) × (격자 내 관로의 개수)

GNN-based Structural Risk Heatmap for Seoul



GNN-based Structural Risk Heatmap for Seoul (Neighborhood Level)



순위	구 이름	총 Hexbin 수	위험 Hexbin 수	위험 Hexbin 비율 (%)	실제 침하 수
1	중구	615	143	23.25	2
2	성동구	847	157	18.54	2
3	용산구	924	169	18.29	1
4	마포구	1085	155	14.29	4
5	중랑구	885	115	12.99	2
6	종로구	936	119	12.71	3
7	동작구	881	111	12.6	1
8	은평구	1137	142	12.49	2
9	동대문구	860	105	12.21	3
10	서대문구	859	100	11.64	5

순위	구 이름	총 Hexbin 수	위험 Hexbin 수	위험 Hexbin 비율 (%)	실제 침하 수
11	노원구	1126	125	11.1	3
12	구로구	1108	116	10.47	4
13	강서구	1464	141	9.63	4
14	영등포구	1162	103	8.86	4
15	서초구	1666	145	8.7	3
16	송파구	1571	134	8.53	10
17	도봉구	775	62	8	2
18	강동구	1087	77	7.08	5
19	광진구	794	55	6.93	0
20	관악구	973	66	6.78	2
21	성북구	1121	75	6.69	8
22	금천구	655	39	5.95	1
23	강남구	1926	113	5.87	11
24	강북구	706	27	3.82	2
25	양천구	980	33	3.37	1

FUTURE GOAL

행정동 별로 구분하여 좀더 상세한 분류

SPATIO-TEMPORAL GNNS 모델 활용